

基于一致性建模的少样本缺陷图像生成

石清风^{1,2}、魏静²、沉飞^{1,2,3}、张正涛^{1,2,3}

¹ 中国科学院自动化研究所 ² 中国科学院大学人工智能学院 ³ 中科院视觉科技有限公司, 洛阳, 中国 {shiqingfeng2022, weijing2020, fei.shen, zhengtao.zhang}@ia.ac.cn

抽象的。图像生成可以解决缺陷检测中标记数据不足的问题。大多数缺陷生成方法仅针对单个产品进行训练, 没有考虑多个产品之间的一致性, 导致生成结果的质量差和多样性。为了解决这些问题, 我们提出了DefectDiffu, 一种新颖的文本引导扩散方法, 可以对多个产品的产品内背景一致性和产品间缺陷一致性进行建模, 并调节一致性扰动方向来控制产品类型和缺陷强度, 实现多样化的缺陷图像生成。首先, 我们利用文本编码器分别为解开的集成架构的背景、缺陷和融合部分提供一致性提示, 从而解开缺陷和正常背景。其次, 我们提出了双自由策略, 通过一致性方向的两阶段扰动生成缺陷图像, 从而通过调整扰动尺度来控制产品类型和缺陷强度。此外, DefectDiffu 可以利用缺陷部分的交叉注意力图生成缺陷掩模注释。最后, 为了提高小缺陷和掩模的生成质量, 我们提出了自适应注意力增强损失来增加对缺陷的关注。实验结果表明, DefectDiffu在生成质量和多样性方面超越了最先进的方法, 从而有效提高了下游缺陷性能。此外, 缺陷扰动方向可以在各种产品之间转移, 以实现零样本缺陷生成, 这对于解决数据不足的问题非常有益。代码可在 <https://github.com/FFDD-diffusion/DefectDiffu> 获取。

K 关键词: 扩散模型·图像生成·缺陷检测 的

1 简介

基于深度学习的检测算法对于制造[28]、交通运输[18]和电力系统[1]等工业应用至关重要。有效的缺陷检测方法有助于识别正常产品中的异常情况[27]。然而, 检测算法的性能通常与注释样本的数量正相关。随着改善




图 1: 产品内背景和产品间缺陷一致性示例

在生产过程中，缺陷在生产线上变得越来越少，并且只占据物体的一小部分[34]，这给数据收集和注释带来了挑战。最近，利用生成对抗网络（GAN）[8]和去噪扩散概率模型（DDPM）[9]进行图像合成吸引了大量研究[16]，在生成逼真图像[29][3][15]方面取得了令人印象深刻的进展。最近的工作[35][19][20][21][5][11]证明了生成逼真的缺陷图像来解决缺陷图像稀缺问题的可行性。然而，现有方法在处理有限的缺陷训练样本时面临挑战，例如过度拟合、多样性差和注释不准确。

这些挑战源于这样一个事实：当前的方法主要侧重于针对特定场景的定制设计，而忽略了工业缺陷图像中两个关键的一致性问题。首先，单一产品的各种缺陷均源于正常区域。如图1第一行所示，缺陷图像和正常图像的正常区域是一致的，突出了产品内背景的一致性。其次，如图1第二行所示，不同产品中同一类别的缺陷表现出形态相似性，说明了产品间缺陷的一致性。利用这些一致性，缺陷图像生成可以分为两个步骤：正常特征生成和缺陷特征转换。值得注意的是，同一产品内正常背景的生成方向应保持一致，而不同产品的相似缺陷之间的缺陷生成方向应一致，方向尺度反映缺陷的强度。与对单一类型产品的缺陷分布进行建模相比，对多种产品的两种一致性进行建模可以丰富用于生成的可用训练数据。因此，对两种一致性进行建模对于利用有限的训练样本生成高质量且多样化的缺陷图像至关重要。最近，预训练的视觉语言模型 CLIP [23] 展示了卓越的零样本能力，表现出强大的泛化能力。这种能力很大程度上归功于 CLIP 对齐文本和图像以有效地建模目标对象的一致性。在下游任务中，CLIP通常是

用于对图像之间的一致性信息进行建模。在异常检测中，WinCLIP [12]和AnomalyCLIP [40]利用预先训练的CLIP对异常的一致性进行建模，实现零样本异常检测。在图像生成中，基于扩散模型的文本到图像生成已显示出有希望的结果。文本提示由CLIP的文本编码器进行编码，为生成提供一致的条件，并引导扩散模型生成符合文本提示的图像，从而实现多样化的生成。DreamBooth[26]将唯一标识符与特定的生成主题绑定，以实现主题驱动的生成。Custom Diffusion [17]仅通过四张图像优化了文本到图像调节机制中的几个参数，使模型能够学习新概念并实现多个概念的组合。

基于上述分析，我们提出了一种新颖的文本引导扩散方法DefectDiffu，对多个产品的产品内背景一致性和产品间缺陷一致性进行建模，以少样本训练样本实现可控的多样化缺陷图像生成。首先，我们介绍一个解耦的集成架构，包括三个关键部分：背景、缺陷和融合。然后通过文本编码器将多个单对象文本条件输入到每个部分，以方便背景和缺陷的解开和融合，实现两者一致性的建模。此外，我们从缺陷部分提取交叉注意力图，以导出准确的二进制掩模注释。其次，我们提出了双自由策略来具体化两个一致性方向。双自由允许通过调整一致性扰动方向来灵活控制产品类型和缺陷强度。最后，针对小缺陷生成不良和掩模不准确的问题，我们引入自适应注意力增强损失来提高对缺陷区域的注意力，提高小缺陷和掩模的生成质量。此外，我们还探索了 DefectDiffu 通过转移缺陷扰动方向来生成零样本缺陷的能力。本文的主要贡献如下：

- 1) 我们提出DefectDiffu，使用文本引导的解耦集成架构对多个产品的产品内背景一致性和产品间缺陷一致性进行建模，以有限的样本实现可控的缺陷图像生成，并在生成过程中获得掩模。
- 2) 我们提出了双自由策略来具体化背景和缺陷扰动方向，允许调整扰动尺度来控制产品类型和缺陷强度，并进一步探索零样本缺陷生成能力。
- 3) 我们引入自适应注意力增强损失来提高小缺陷的生成质量和掩模的准确性。

2 相关工作

2.1 可控图像生成

基于扩散的生成。基于扩散的生成。近年来，由于扩散模型在图像生成方面经历了快速发展

以其高生成质量和训练稳定性，在生成图像的真实性和多样性方面超越了 GAN 和 VAE（变分自编码器）[14]，成为最突出的图像生成模型，特别是在可控图像生成方面。[4]专注于在噪声图像上预训练分类器，使用噪声图像的分类梯度来指导类别可控的生成。[10]提出了无分类器指导，同时训练条件和无条件模型，利用它们的差异作为显式分类器的替代品。DiT [22] 用 Transformer 取代了扩散模型中常用的 UNet 架构，以从条件中学习自适应归一化层的参数，从而在 ImageNet 上实现了最先进的性能。

文本引导图像生成。最近，基于扩散模型的大规模模型，例如 DALL-E 2 [24]、Imagen [37] 和 Stable 扩散 [25]，已经展示了令人印象深刻的文本引导图像生成能力，能够精确控制生成的语义内容 [39][38]。交叉注意机制是将文本引导引入生成模型的最常用方法，其中交叉注意图反映了生成图像中文本标记对应的位置。为了确保生成的图像和文本提示之间的对齐，Attend-and-Excite [2]、MaskDiffusion [41] 和 StructureDiffusion [6] 修改交叉注意力以增强模型对每个标记的关注。有些作品通过处理交叉注意力图来实现标签生成和图像编辑。DiffuMask [31] 提取交叉注意力图并通过亲和网络获得生成图像的伪掩模。Attn2Mask [33] 使用后处理的交叉注意力图作为训练分割模型的伪掩模。Prompt-to-Prompt 在生成过程中动态改变交叉注意力图，以实现灵活的图像编辑。文本引导模型展示了从图像中学习高级语义信息的能力 [26][17][7]，允许通过使用一些图像和文本描述微调预训练模型来进行定制生成。

2.2 缺陷图像生成

缺陷图像生成广泛用于解决检测任务中数据不足的问题。当前大多数方法都采用 GAN 来生成带有二进制掩模的缺陷图像（例如 DefectGAN [36]、SDGAN [19]、AnomalyGAN [18]）。MDGAN [30] 基于 Perlin 噪声构建的掩模和真实正常样本上的缺陷注释来合成缺陷。[20] 和 [19] 将图像编码到特征空间中，建立正常图像和缺陷图像之间的变换方向，并调整变换因子以实现强度可控的缺陷图像生成。DFMGAN [5] 在正常样本上预训练 StyleGAN v2 [13]，并使用一些缺陷样本进行微调，以更新建议的掩模和缺陷生成模块。目前，一些工作探索了基于扩散模型的少样本缺陷图像生成。为了提高生成质量，Defect-Gen [32] 训练了两个扩散模型，大模型用于确定

生成的目标结构和用于细节生成的小模型。然而，这些方法需要为每个产品训练单独的模型。Anomalydiffusion [11]通过文本翻转生成掩模，采用正常样本和掩模作为输入来生成多个产品的缺陷图像。然而，预定义的掩模和正常样本限制了缺陷形状和正常背景的多样性。此外，上述方法无法对多个产品的相似缺陷之间的关系进行建模，导致泛化能力较差。相比之下，DefectDiffu对多个产品的图像一致性进行建模，并基于交叉注意力图获得掩模，从而整合多个产品的特征来生成多样化的缺陷图像，并避免预定义掩模的限制。

3 方法

如图2所示，DefectDiffu采用预训练的DiT作为主干，由条件模块、生成模块和掩模生成模块组成。条件模块采用CLIP文本编码器将一致的文本提示引入生成模块的相应部分。生成模块采用解缠式集成架构，解开正常背景和缺陷的生成，然后在文本提示的引导下将其集成生成逼真的图像。掩模生成模块集成缺陷块的交叉注意力图以获得与生成的图像相对应的掩模注释。此外，Adaptive Loss Ratio旨在调整缺陷区域的损失权重，增强DefectDiffu对缺陷的关注。接下来，我们提出了一种双自由策略来具体化建模的一致性，从而通过调节去噪结果来实现产品类型和缺陷强度的可控生成。

3.1 预备知识

基于DDPM的图像生成由前向噪声添加过程和反向去噪过程组成。在前向过程中，将高斯噪声添加到输入图像 x_0 中 T 次，得到纯噪声图像 x_T ,

$$q(x_{1:T}|x_0) := \prod_{t=1}^T q(x_t|x_{t-1}), q(x_t|x_{t-1}) := N(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I) \quad (1)$$

其中 β_t 是时间步 t 处的方差。在反向去噪过程中，噪声预测模型 ϵ_θ 从噪声图像 x_t 中恢复 x_0 ，其中 θ 表示可学习的模型参数。 ϵ_θ 将 x_t 和当前时间步长 t 作为输入来预测该时间步长去除的噪声。此外，当以文本、图像或其他信息作为条件 c 实现可控图像生成时， ϵ_θ 将 x_t 、时间步长 t 和条件 c 作为输入来预测噪声。模型的训练目标是：

$$\min_{\theta} L = \mathbb{E}_{x_t, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t, c)\|_2^2] \quad (2)$$




图2: DefectDiffu的总体框架。在训练过程中, 真实图像和掩模由图像编码器编码到特征空间中, 然后用于训练生成模块和掩模生成模块。调整真实掩模的大小以计算自适应损失率。在测试过程中, 生成的图像特征和掩模特征由图像解码器解码以获得图像掩模对。

3.2 文本引导的解缠集成架构

为了对产品内背景一致性和产品间缺陷一致性进行建模, 需要为DefectDiffu和设计架构提供包含一致性信息的条件, 以实现一致性信息引导的解缠生成。首先, 如图2所示, 我们采用产品名称和缺陷名称分别作为产品内一致性和产品间缺陷一致性文本提示, 利用CLIP文本编码器构建一致性指导。以前的文本转图像生成方法使用一张{object 1} {object 2} {object n}的照片来控制多个对象的生成, 这不适合我们的工作。原因是文本编码器将一个文本提示中的多个对象编码为融合输出。尽管这种融合输出可以指导模型生成高质量图像, 但很难在生成过程中解开多个对象, 并可能导致灾难性的忽视[2]。然而, 解开缺陷和背景是对多个产品的两种一致性进行建模的关键点。因此, 我们使用两个单对象提示作为条件来建模一致性, 实现背景和缺陷的分离生成。此外, 与基于UNet的扩散架构相比, DiT具有基于变压器的可扩展分层堆叠架构。它允许我们在模型的每个部分引入不同的条件来学习多个对象的解缠生成。

因此, 如图2所示, 结合单目标引导的优点和DiT的灵活性, 我们提出了文本引导解缠集成架构 (TDIA)。TDIA将DiT分为三部分, 背景、缺陷、融合。背景部分引入了用于建模背景一致性的背景文本嵌入, 用于建模的缺陷文本嵌入

缺陷部分引入缺陷一致性，融合部分采用缺陷-背景融合文本嵌入来生成逼真的缺陷图像。各部分设计的文字提示模板如下：

背景块的一致性条件 c_p :

{产品名称}的照片

缺陷块的一致性条件 c_d :

A photo of {defect name}

Fusion Block 的融合条件 c_f :

{缺陷名称} {产品名称}的照片

3.3 双免

尽管DefectDiffu在通过TDIA对两个一致性进行建模后可以生成以 c_p 和 c_d 为条件的多样化缺陷图像 $\epsilon_\theta(x_t, t, c_d, c_p)$ ，但生成的缺陷的强度无法控制并且仅限于训练集分布，从而影响了生成的多样性。我们假设应该存在一个扰动方向，沿着该扰动方向，正常图像逐渐变成缺陷图像，并且扰动尺度反映了缺陷强度。因此，我们将可控缺陷图像的生成视为涉及背景和缺陷的两阶段扰动过程，通过改变扰动尺度来调节缺陷强度。我们将 F_p^t 和 F_d^t 设置为关于时间步 t 处两个一致条件 c_p 和 c_d 的扰动方向。然后通过调整扰动尺度 w_d 和 w_p 来更新去噪结果，实现可控生成

$$\epsilon_\theta(x_t, t, c_d, c_p) = \epsilon_\theta(x_t, t, \emptyset, \emptyset) + w_p F_d^t + w_d F_p^t \quad (3)$$

为了计算两个扰动方向，我们提出了基于无分类器指导的双自由策略，实现了超越训练集多样性的背景和缺陷强度可控生成。首先，将 $\epsilon_\theta(x_t, t, c_g, c_p)$ 视为正常背景的条件生成，其中 c_g 是好的，通过将 c_p 设置为空得到 $\epsilon_\theta(x_t, t, c_g, \emptyset)$ 来实现无条件背景生成，差值 $F_p^t = \epsilon_\theta(x_t, t, c_g, c_p) - \epsilon_\theta(x_t, t, c_g, \emptyset)$ 是产品内一致性的扰动方向，实现可控背景生成。在此基础上，将产品间缺陷一致性指导视为缺陷 $\epsilon_\theta(x_t, t, c_d, \emptyset)$ 的条件生成，对应的无条件生成 $\epsilon_\theta(x_t, t, c_g, \emptyset)$ ，差值 $F_d^t = \epsilon_\theta(x_t, t, c_d, \emptyset) - \epsilon_\theta(x_t, t, c_g, \emptyset)$ 为产品间缺陷一致性的扰动方向。然后设置缺陷相对于正常图像的扰动方向尺度 w_d ，以实现缺陷强度的可控生成。最后，方程。(3)可以简化为：

$$\begin{aligned} \epsilon_\theta(x_t, t, c_d, c_p) &= \epsilon_\theta(x_t, t, c_g, \emptyset) + w_p(\epsilon_\theta(x_t, t, c_g, c_p) - \epsilon_\theta(x_t, t, c_g, \emptyset)) \\ &\quad + w_d(\epsilon_\theta(x_t, t, c_d, \emptyset) - \epsilon_\theta(x_t, t, c_g, \emptyset)) \end{aligned} \quad (4)$$

Algorithm 1 Double-free guidance.

Input: Training data (x, c_d^r, c_p^r) from the dataset, p_1 : probability of unconditional product, p_2 : probability of unconditional defect, $c_d = c_d^r, c_p = c_p^r$

Output: Condition modified data, (x, c_d, c_p) ;

- 1: with probability $p_1, c_p \rightarrow \emptyset$
- 2: **If** c_d^r is not *good*:
- 3: with probability $p_2, c_d \rightarrow \text{good}$;
- 4: with probability $p_1, c_p \rightarrow \emptyset$;
- 5: **return** (x, c_d, c_p) ;

其中 w_p 和 w_d 分别控制背景的表达和缺陷的强度。double-free的算法如算法1所示。

3.4 掩模生成

当使用生成的图像训练分割模型时，手动获取像素级掩模注释既费力又耗时。因此，如图2所示，我们在缺陷块中采用交叉注意机制，并将其与掩模生成模块相结合，在生成缺陷图像的同时生成相应的掩模。交叉注意力适用于融合视觉和文本特征的嵌入，并为每个文本标记生成空间注意力图。噪声特征 $\varphi(x_t) \in \mathbb{R}^{H \times W \times C}$ 被投影到查询向量 $Q \in \mathbb{R}^{H \times W \times d}$ ，其中 H 、 W 和 C 分别是张量的长度、宽度和通道数， d 是 Q 的维度。长度为 l 的文本嵌入 $p \in \mathbb{R}^{l \times C}$ 被投影以获得键向量 $K \in \mathbb{R}^{l \times d}$ 和值向量 $V \in \mathbb{R}^{l \times d}$ 。然后交叉注意力计算如下：

$$CrossAttention = Softmax\left(\frac{QK^T}{\sqrt{d}}\right) \quad (5)$$

接下来，我们沿着通道维度连接多个缺陷块的交叉注意力图，然后通过掩模生成模块获得掩模特征 M_f ，然后解码 M_f 以获得值在 $[0, 255]$ 之间的像素级掩模 M_{pre} 来定位生成的缺陷位置。真实掩模被编码为羽毛 $Mask_f$ ，掩模预测损失为：

$$loss_m = \|M_f - Mask_f\|_2^2 \quad (6)$$

随着时间步长的增加，图像的高级语义结构将逐渐显现。因此，为了准确定位缺陷，我们计算测试过程中最后100个时间步获得的平均掩模 $M_{pre} = \frac{1}{100} \sum_{t=0}^{99} M_{pre}^t$ ，并使用迭代方法对 M_{pre} 进行二值化以获得最终掩模。

3.5 自适应注意力增强损失

在训练过程中，我们发现 DefectDiffu 倾向于忽略缺陷特征并轻松生成正常图像。此外，生成的掩码不准确

适用于单个图像中涉及小缺陷或多个缺陷的情况。原因在于，与正常区域相比，比例较小的缺陷区域的特征更难以捕捉。此外，如等式所示。(2)、扩散模型的训练目标是 minimized 全局重建损失，其中缺陷的重建损失对整体损失的贡献较小。因此，模型对缺陷区域关注不够，导致重建效果差和标注不准确。为了解决这些问题，我们提出了基于交叉注意力图的自适应注意力增强损失，以增加缺陷区域的损失权重，从而增强 DefectDiffu 对缺陷的注意力。首先，我们从提取的缺陷块的交叉注意力图中计算平均交叉注意力 Map ：

$$Map = \frac{1}{M} \sum_{i=0}^M Softmax\left(\frac{Q_i K^T}{\sqrt{d}}\right) \quad (7)$$

其中 M 是提取的交叉注意力图的数量。将真实的 $Mask$ 缩放为与 Map 大小相同的 $mask$ ，提取缺陷区域和正常区域的注意力，然后计算各自的总和以获得自适应注意力比率：

$$Rat = \frac{\sum_{i,j} (1 - mask)_{i,j} \cdot Map_{i,j}}{\sum_{i,j} mask_{i,j} \cdot Map_{i,j} + \alpha} \quad (8)$$

其中 i 和 j 是 Map 的高度和宽度， α 是用于防止被零除的常数。分配给缺陷区域的注意力越低， Rat 就越高。为了防止缺陷区域权重过高导致缺陷区域和背景区域不平衡，我们进一步修改注意力比率 Rat 的大小以获得 R ，

$$R(Rat) = \begin{cases} 8, & Rat \geq 8 \\ Rat, & 2 < Rat < 8 \\ 2, & Rat \leq 2 \end{cases} \quad (9)$$

那么改进后的缺陷区域损失为：

$$loss_d = R \|mask \cdot \epsilon_\theta(z_t, t, c_d, c_p) - mask \cdot \epsilon\|_2^2 \quad (10)$$

最后，DefectDiffu 的训练目标是：

$$\min_{\theta} loss = \|\epsilon_\theta(z_t, t, c_d, c_p) - \epsilon\|_2^2 + loss_d + \lambda loss_m \quad (11)$$

其中 λ 是超参数。

3.6 零样本生成

基于TDIA和双自由策略，DefectDiffu可以跨不同产品的正常背景转移缺陷特征，从而实现零样本




图 3: 生成结果比较。

缺陷的产生。训练时只使用目标产品 T 的正常样本，测试时将从源产品学习到的缺陷 c_d^s 的扰动方向添加到 T 的正常图像的生成中，从而生成带有缺陷 c_d^s 的 T 的缺陷样本。具体来说，在测试过程中，模型同时输入产品提示 c_T 和缺陷提示 c_d^s 。然后计算在其他产品上建模的 c_d^s 的扰动方向，以更新时间步 t 的去噪结果，

$$\begin{aligned} \epsilon_{\theta}(x_t, t, c_d^s, c_T) = & \epsilon_{\theta}(x_t, t, c_g, \emptyset) + w_p(\epsilon_{\theta}(x_t, t, c_g, c_T) - \epsilon_{\theta}(x_t, t, c_g, \emptyset)) \\ & + w_d(\epsilon_{\theta}(x_t, t, c_d^s, \emptyset) - \epsilon_{\theta}(x_t, t, c_g, \emptyset)) \end{aligned} \quad (12)$$

因此，DefectDiffu 可以生成 T 的缺陷图像，而不需要相应的真实缺陷图像进行训练，这归因于我们成功地模拟了产品间缺陷一致性的扰动方向。

4 实验

4.1 实验设置

数据集和评估指标。我们在 MVTecAD 数据集上进行实验来验证 DefectDiffu 的有效性。我们从 MVTecAD 测试中选择一半图像作为图像生成和基线的训练集

表 1: 比较和消融实验的质量和多样性评估结果。我们的 DefectDiffu 在 MVTec 数据集上取得了最佳结果。

Category	DefectDiffu		Defect-Gen		DFMGAN		StyleGAN2		w/o fusion		w/o AAL		OPT	single
	FID	LPIPS	FID	LPIPS	FID	LPIPS	FID	LPIPS	FID	LPIPS	FID	LPIPS	FID	LPIPS
bottle	73.48	0.16	124.86	0.10	130.69	0.13	112.79	0.08	132.20	0.08	134.76	0.08	127.12	0.09
cable	101.69	0.29	158.82	0.24	111.38	0.27	144.33	0.17	112.48	0.10	108.30	0.10	185.85	0.28
capsule	26.85	0.08	70.36	0.02	50.54	0.05	25.62	0.03	57.68	0.05	60.35	0.03	70.43	0.07
carpet	40.31	0.17	51.35	0.13	45.09	0.16	40.34	0.14	44.56	0.10	43.85	0.10	77.25	0.16
grid	62.55	0.35	136.62	0.30	84.58	0.34	90.91	0.33	75.91	0.24	81.45	0.24	161.24	0.35
hazelnut	70.18	0.17	434.55	0.13	378.17	0.20	435.11	0.20	420.76	0.15	464.62	0.13	185.90	0.17
leather	67.19	0.15	470.15	0.10	95.84	0.31	369.94	0.14	96.94	0.10	88.45	0.09	435.32	0.14
metal_nut	59.46	0.29	168.21	0.47	151.68	0.33	87.56	0.18	158.56	0.25	172.42	0.19	232.26	0.29
pill	46.23	0.15	258.37	0.42	133.07	0.14	227.78	0.02	162.59	0.06	152.54	0.07	186.61	0.14
screw	26.11	0.27	217.84	0.42	71.06	0.26	32.59	0.26	70.54	0.17	71.36	0.18	120.84	0.26
tile	120.39	0.36	333.24	0.24	162.14	0.18	136.40	0.26	152.25	0.22	158.48	0.22	162.18	0.34
toothbrush	110.59	0.14	196.56	0.13	224.22	0.24	48.08	0.12	220.34	0.19	212.30	0.16	418.58	0.13
transistor	69.25	0.24	173.35	0.21	142.69	0.28	67.07	0.26	127.27	0.19	123.21	0.11	204.25	0.20
wood	128.26	0.27	333.03	0.19	315.69	0.23	188.20	0.34	331.29	0.19	325.66	0.16	305.98	0.23
zipper	37.74	0.12	378.24	0.48	80.97	0.07	78.18	0.16	89.36	0.05	93.80	0.05	89.48	0.11
Average	69.35	0.21	233.70	0.24	145.19	0.21	138.99	0.18	149.83	0.14	152.77	0.13	197.55	0.20

在分割实验中，将剩余图像用作测试集，以评估生成图像在缺陷检测中的有效性。所有图像的大小均调整为 512×512 。分别计算 FID（Fréchet Inception Distance）和 LPIPS（Learned Perceptual Image patch Simity）用于质量和多样性评估。FID 越低表示发电质量越高。LPIPS 越高表明多样性越好。对于下游应用，我们计算了 mIOU（平均交集）、F1 分数、mAP（平均平均精度）和 AUROC（接收器操作特征曲线下的面积）来评估生成的图像掩模对的有效性，值越高表示性能越好。

执行。我们将图 2 中的 N、M 和 K 分别设置为 10、10 和 8。相应模块的参数使用 ImageNet 中预训练的 DiT 进行初始化，分辨率为 512×512 。我们在方程 (1) 中设置 $\lambda = 0.2$ 。(11)、等式中的 $p_1 = 0.2$ 、 $p_2 = 0.2$ 、 $\alpha = 0.001$ (8)。我们使用迭代阈值方法对生成的掩模进行二值化。请参阅附录了解更多详细信息。

比较方法。我们使用 StyleGAN2、DFMGAN 和 Defect-Gen 作为比较方法。StyleGAN2 在自然图像生成方面显示出了有希望的结果，并且通常用作工业图像生成的基础框架。DFMGAN 专注于基于 StyleGAN2 的少样本缺陷生成。Defect-Gen 利用两个扩散模型来生成缺陷及其相应的掩模。它们是当前使用带注释掩模生成工业图像的最先进方法。值得注意的是，这些模型需要针对每个产品单独进行训练。比较方法的实现细节见附录。




图4: 不同强度下的生成结果, 缺陷强度从左到右逐渐增加。

4.2 生成结果比较

图3显示了不同方法的生成结果, 更多结果参见附录。可以看出, Defect-Gen 未能对现实的高级语义特征进行建模, 并且生成的缺陷与真实的缺陷特征不匹配。DFMGAN 会产生不切实际的缺陷并包含大量伪影。StyleGAN2 未能在皮革上收敛, 并在电缆等产品中表现出伪影。相比之下, DefectDiffu 在所有 15 个产品中实现了良好的收敛。生成的结果符合真实特征, 没有模式崩溃或伪影, 并且掩模是准确的, 验证了所提出的用于少样本图像生成的多产品一致性建模的有效性。另外, 图4展示了利用 w_d 控制缺陷强度。随着 w_d 的增加, 产生缺陷的面积扩大, 缺陷区域的数量增加, 表明产品损坏的严重程度逐渐增加。

标签。图 1 显示我们的方法在 MVTec 数据集上实现了最佳生成质量和良好的多样性。虽然牙刷的生成质量略逊于 StyleGAN2, 但 DefectDiffu 同时生成缺陷掩模, 这更有利于训练分割方法。尽管 DFMGAN 和 Defect-Gen 在某些产品上实现了更高的 LPIPS, 但由于引入了不切实际的伪影和丢失了真实的语义特征。见图3和表1。从图1可以看出, 这些产品的发电质量较差, 对应的FID较高。显然, 没有坚持的多样性

表2: 检测性能比较。

Category	Baseline				DefectDiffu				Defect-Gen				DFMGAN			
	mIoU	F1	mAP	AUC	mIoU	F1	mAP	AUC	mIoU	F1	mAP	AUC	mIoU	F1	mAP	AUC
bottle	66.1	79.6	89.7	98.7	75.7	86.2	93.8	99.2	76.0	86.3	93.2	99.0	71.3	83.2	92.3	98.8
cable	55.0	71.0	76.0	92.2	62.5	76.9	81.8	95.1	60.5	75.4	80.6	95.1	58.4	73.7	78.0	91.8
capsule	28.2	44.0	42.2	94.1	34.2	51.0	54.9	97.2	31.4	47.8	47.5	91.2	33.1	49.8	56.4	96.8
carpet	64.8	78.6	88.8	99.6	69.8	82.2	90.9	99.6	67.4	80.5	89.8	99.3	66.1	79.6	88.8	99.5
grid	32.7	49.3	46.6	95.8	47.3	64.2	69.4	99.3	35.6	52.5	49.6	97.4	37.4	54.4	63.8	98.8
hazelnut	85.0	91.9	96.9	99.6	87.2	93.2	97.5	99.7	87.4	93.3	97.9	99.8	83.1	90.8	96.4	99.5
leather	67.4	80.5	89.6	99.8	67.9	80.9	88.1	99.7	68.3	81.1	89.9	99.8	65.3	79.0	88.4	99.8
metal_nut	86.9	93.0	97.6	99.3	91.5	95.6	99.0	99.7	89.5	94.5	98.8	99.8	73.0	84.4	92.4	97.9
pill	76.1	86.4	95.2	99.7	83.4	90.9	97.4	99.8	69.5	82.0	91.8	99.0	76.8	86.9	94.3	99.3
screw	26.1	41.4	47.0	98.3	48.9	65.7	76.6	99.7	43.0	60.1	69.9	98.5	32.7	49.3	57.9	98.1
tile	86.7	92.9	98.2	99.8	89.7	94.6	98.8	99.9	89.1	94.2	98.9	99.9	87.7	93.4	98.6	99.8
toothbrush	34.5	51.3	56.6	95.8	44.0	61.1	60.2	96.2	44.8	61.8	60.7	97.0	34.2	31.4	47.8	58.3
transistor	58.2	73.6	78.9	96.0	64.3	78.3	79.2	97.1	52.8	69.1	84.6	96.7	48.7	65.5	74.7	94.4
wood	68.3	81.1	89.5	97.7	69.4	81.9	89.8	98.3	69.3	81.9	89.5	98.0	66.5	79.9	88.1	97.8
zipper	67.9	80.8	87.7	99.3	70.7	82.9	90.2	99.6	68.6	81.4	88.9	99.4	70.8	82.9	89.2	99.6
Average	60.3	73.0	78.7	97.7	67.1	79.0	84.5	98.7	63.5	76.1	82.1	98.0	60.3	72.3	80.5	95.4




图 5: 零样本生成结果。A-B表示将源缺陷A转移到目标产品B。

真实的特征是没有意义的。相比之下, DefectDiffu 在大多数产品上实现了最佳的生成质量, 同时保持了良好的多样性。

4.3 检测结果比较。

为了验证生成结果在工业检测中的有效性, 我们使用真实训练集来训练 UNet 作为基线, 并通过能够生成掩模来增强真实数据集的方法生成两倍于真实图像大小的合成样本。分割结果如表1所示。2. 与其他方法相比, DefectDiffu 可以提高所有产品的性能, 并在大多数产品上达到最优的分割结果。附录中提供了更多结果。综上所述, DefectDiffu能够有效提升检测方法的性能, 具有较高的应用价值。

4.4 零样本生成

如第 2 节所述。3.6, 我们验证了DefectDiffu的零样本生成能力, 结果如图5所示。虽然DefectDiffu在训练过程中只学习了目标产品正常图像的特征, 但从其他产品建模的缺陷一致性扰动方向有效地指导了目标产品缺陷的生成。这使得DefectDiffu 能够实现

零样本缺陷生成，在训练过程中无需目标产品的真实缺陷图像。更多结果请参见附录。

4.5 消融实验

融合部分。我们去掉生成模块中的融合部分，结果如表2所示。1 无融合。如果没有融合部分，生成的缺陷和背景之间的语义一致性就会被破坏，导致生成质量和多样性下降。

AAL（自适应注意力增强损失）。我们将等式中的 R 设置为 3。(9) 训练 Defect Diffu，结果如表2所示。1 不带 AAL。这表明如果没有 AAL，生成结果的质量和多样性都会下降，这表明 AAL 有助于防止缺陷特征的丢失并提高生成的缺陷图像的质量。

多个单一对象提示。为了验证TDIA中多个单对象提示对提高缺陷图像生成质量的作用，我们仅使用融合部分的文本提示作为 DefectDiffu 的条件，生成结果的质量如表2所示。1 个一次性密码。可以看出，采用单个文本提示来控制多个对象的生成会对生成质量产生不利影响。

缺陷强度等级 w_d 。我们设置 $w_d=1$ 并在多个强度尺度上生成相同数量的缺陷图像，以验证多强度生成对多样性的影响。LPIPS 结果如表 1 所示。1 单人。可以看出，在单一尺度下，多样性有所降低，但在大多数产品中仍然优于比较方法。这表明 DefectDiffu 通过双重释放策略有效地扩展了数据集的多样性。

5 结论

本文提出 DefectDiffu 来实现在有限样本的多个产品中可控地生成缺陷图像掩模对。DefectDiffu 利用解开的集成架构和多个单对象文本提示来解开缺陷和正常背景，有利于产品内背景一致性和产品间缺陷一致性的建模，从而增强正常背景和缺陷的多样性。此外，提出了双自由策略来具体化建模的背景一致性和缺陷一致性的扰动方向，从而实现多属性可控生成。实验结果表明，DefectDiffu 在生成质量和多样性方面均优于最先进的方法，有效增强了检测性能。此外，DefectDiffu 基于产品间缺陷一致性实现了零样本缺陷生成，降低了与数据收集和注释相关的成本。

致谢

这项工作得到了国家重点研发计划 (2022YFB3303800)、国家自然科学基金 (U21A20482) 和北京市自然科学基金 (L243018) 的支持。

参考

1. Ahmed, C.M., M R, G.R., Mathur, A.P.: 工业控制系统中基于机器学习的实时异常检测方法面临的挑战。见：第六届 ACM 网络物理系统安全研讨会论文集 (2020 年 10 月)。 <https://doi.org/10.1145/3384941.3409588>, <http://dx.doi.org/10.1145/3384941.3409588>
2. Chefer, H., Alaluf, Y., Vinker, Y., Wolf, L., Cohen-Or, D.: 参与和激发: 文本到图像扩散模型的基于注意力的语义指导 (2023 年 1 月)
3. Crowson, K., Biderman, S., Kornis, D., Stander, D., Hallahan, E., Castriato, L., Raff, E.: Vqgan-clip: 使用自然语言指导生成和编辑开放域图像。见：欧洲计算机视觉会议。第 88–105 页。Springer (2022)
4. Dhariwal, P., Nichol, A.: 扩散模型在图像合成方面击败了 GANs。神经信息处理系统进展 34, 8780–8794 (2021)
5. Duan, Y., Hong, Y., Niu, L., Zhuang, L.: 通过缺陷感知特征操作生成少量缺陷图像 (2023 年 3 月)
6. Feng, W., He, X., Fu, T.J., Jampani, V., Akula, A., Narayana, P., Basu, S., Wang, X.E., Wang, W.Y.: 用于组合文本到图像合成的免训练结构化扩散指导。arXiv 预印本 arXiv:2212.05032 (2022)
7. Gal, R., Alaluf, Y., Atzmon, Y., Patashnik, O., Bermano, A.H., Chechik, G., Cohen-Or, D.: 一幅图像胜过一个词: 使用文本反转个性化文本到图像的生成。arXiv 预印本 arXiv:2208.01618 (2022)
8. Goodfellow, I.J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., Bengio, Y.: 生成对抗网络。见：第 27 届神经信息处理系统国际会议论文集 - 第 2 卷。2672–2680。NIPS' 14, 麻省理工学院出版社, 剑桥, 马萨诸塞州, 美国 (2014)
9. Ho, J., Jain, A., Abbeel, P.: 去噪扩散概率模型。神经信息处理系统, 神经信息处理系统 (2020 年 1 月)
10. Ho, J., Salimans, T.: 无分类器扩散指导。arXiv 预印本 arXiv:2207.12598 (2022)
11. Hu, T., Zhang, J., Yi, R., Du, Y., Chen, X., Liu, L., Wang, Y., Wang, C.: 异常扩散: 利用扩散模型生成少样本异常图像 (2023 年 12 月)
12. Jeong, J., Zou, Y., Kim, T., Zhang, D., Ravichandran, A., Dabeer, O.: Winclip: 零/少样本异常分类和分割 (2023 年 3 月)
13. Karras, T., Laine, S., Aittala, M., Hellsten, J., Lehtinen, J., Aila, T.: 分析和改进 stylgan 的图像质量。见：2020 年 IEEE/CVF 计算机视觉和模式识别会议 (CVPR)。第 8107–8116 页 (2020 年)。 <https://doi.org/10.1109/CVPR42600.2020.00813>
14. Kingma, D.P., Welling, M.: 自动编码变分贝叶斯。见：第二届学习表征国际会议, ICMLR 2014, 加拿大艾伯塔省班夫, 2014 年 4 月 14-16 日, 会议记录 (2014)

15. Kowalski, M., Garbin, S.J., Estellers, V., Baltruaitis, T., Johnson, M., Shotton, J.: 配置: 可控神经人脸图像生成。见: 欧洲计算机视觉会议 (ECCV) (2020)
16. Kulikov, V., Yadin, S., Kleiner, M., Michaeli, T.: Sinddm: 单图像去噪扩散模型。见: 国际机器学习会议。第 17920–17930 页。PMLR (2023)
17. Kumari, N., Zhang, B., Zhang, R., Shechtman, E., Zhu, J.Y.: 文本到图像扩散的多概念定制。见: IEEE/CVF 计算机视觉和模式识别会议论文集。pp. 1931–1941 (2023)
18. Liu, R., Liu, W., Cheng, Z., Wang, L., Mao, L., Qiu, Q., Ling, G.: Anomaly-gan: 一种用于列车表面异常检测的数据增强方法。带有应用程序的专家系统 p. 11 120284 (2023 年 10 月)。 <https://doi.org/10.1016/j.eswa.2023.120284>
19. Niu, S., Li, B., Wang, X., Lin, H.: 使用 gan 生成缺陷图像样本以改进缺陷识别。IEEE Transactions on Automation Science and Engineering p. 11 1 日至 12 日 (2020 年 1 月)。 <https://doi.org/10.1109/tase.2020.2967415>, <http://dx.doi.org/10.1109/tase.2020.2967415>
20. Niu, S., Li, B., Wang, X., Peng, Y.: 用于工业图像中缺陷生成和分割的区域和强度可控 gan。IEEE 工业信息学汇刊第 14 页 4531–4541 (2022 年 7 月)。 <https://doi.org/10.1109/tii.2021.3127188>, <http://dx.doi.org/10.1109/tii.2021.3127188>
21. Niu, S., Peng, Y., Li, B., Wang, X.: 一种用于缺陷分割的变换特征空间数据增强方法
22. Peebles, W., Xie, S.: 带有变压器的可扩展扩散模型。见: IEEE/CVF 国际计算机视觉会议论文集。pp. 4195–4205 (2023)
23. Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askel, A., Mishkin, P., Clark, J., et al.: 从自然语言监督中学习可迁移的视觉模型。见: 机器学习国际会议。第 8748–8763 页。PMLR (2021)
24. Ramesh, A., Dhariwal, P., Nichol, A., Chu, C., Chen, M.: 使用剪辑潜伏的分层文本条件图像生成
25. Rombach, R., Blattmann, A., Lorenz, D., Esser, P., Ommer, B.: 使用潜伏扩散模型的高分辨率图像合成。见: 2022 年 IEEE/CVF 计算机视觉和模式识别会议 (CVPR) (2022 年 6 月)。 <https://doi.org/10.1109/cvpr52688.2022.01042>, <http://dx.doi.org/10.1109/cvpr52688.2022.01042>
26. Ruiz, N., Li, Y., Jampani, V., Pritch, Y., Rubinstein, M., Aberman, K.: Dream-booth: 微调文本到图像扩散模型以实现主题驱动生成 (2022 年 8 月)
27. Schlüter, H.M., Tan, J., Hou, B., Kainz, B.: 自然合成异常自监督异常检测和定位。见: 欧洲计算机视觉会议。第 474–489 页。Springer (2022)
28. Singh, S.A., Desai, K.A.: 使用机器视觉和卷积神经网络的自动表面缺陷检测框架。智能制造杂志 p. 1995 年至 2011 年 (2023 年 4 月)。 <https://doi.org/10.1007/s10845-021-01878-w>, <http://dx.doi.org/10.1007/s10845-021-01878-w>
29. Tang, H., Bai, S., Zhang, L., Torr, P.H., Sebe, N.: 用于人物图像生成的Xinggan。于: ECCV (2020)

30. 魏健, 张志, 沉芳, 吕成: 非均匀结构工业缺陷图像掩模引导生成方法。机器 10(12) (2022)。 <https://doi.org/10.3390/machines10121239>、 <https://www.mdpi.com/2075-1702/10/12/1239> 31. Wu, W., Zhao, Y., Shou, M., Zhou, H., Shen, C.: Diffumask: 使用扩散模型合成具有像素级注释的图像以进行语义分割 (2023 年 3 月) 32. Yang, S., Chen, Z., Chen, P., Fang, X., Liu, S., Chen, Y.: 缺陷谱: 具有丰富语义的大规模缺陷数据集的细粒度外观。 arXiv 预印本 arXiv:2310.17316 (2023) 33. Yoshihashi, R., Otsuka, Y., Doi, K., Tanaka, T.: 注意力作为注释: 通过扩散生成弱监督语义分割的图像和伪掩模 (2023 年 9 月) 34. Zavrtnik, V., Kristan, M., Skočaj, D.: Dsr - 用于表面异常检测的双子空间重投影网络 35. Zhang, G., Cui, K., Hung, T.Y., Lu, S.: Defect-gan: 用于自动缺陷检测的高保真缺陷合成。见: 2021 年 IEEE 计算机视觉应用冬季会议 (WACV) (2021 年 1 月)。 <https://doi.org/10.1109/wacv48630.2021.00257>, <http://dx.doi.org/10.1109/wacv48630.2021.00257> 36. 张 G., 崔 K., 洪 T.Y., 卢 S.: Defect-gan: 用于自动缺陷检查的高保真缺陷合成。见: IEEE/CVF 计算机视觉应用冬季会议论文集。 pp. 2524–2534 (2021) 37. Zhang, L., Agrawal, M.: 为文本到图像扩散模型添加条件控制 38. 赵 S., 陈, D., 陈 Y.C., 鲍, J., 郝, S., 袁, L., 黄, K.Y.K.: Unicontrolnet: 文本到图像扩散模型的一体化控制。神经信息处理系统的进展 (2023) 39. 郑 G., 周 X., 李 X., 齐 Z., 单 Y., 李 X.: 布局扩散: 用于布局到图像生成的可控扩散模型。见: IEEE/CVF 计算机视觉和模式识别会议 (CVPR) 会议记录。 pp. 22490–22499 (2023 年 6 月) 40. Zhou, Q., Pang, G., Tian, Y., He, S., Chen, J.: Anomalyclip: 用于零样本异常检测的对象不可知提示学习 (2023 年 10 月) 41. Zhou, Y., Zhou, D., Zhu, Z.L., Wang, Y., Hou, Q., Feng, J.: Maskdiffusion: 通过条件蒙版提高文本到图像的一致性。 arXiv 预印本 arXiv:2309.04399 (2023)

基于一致性建模的少样本缺陷图像生成

补充材料

1 补充实验

1.1 实施

为了对产品间缺陷一致性方向进行建模，我们修改了 MVTecAD 数据集中类似缺陷的缺陷名称。修改前后的缺陷名称如表2所示。 2.

1.2 比较方法的实现

StyleGAN2：我们对每个缺陷类别在StyleGAN2上进行了3000次迭代的训练，批量大小为4。其他参数与官方文档中概述的规范保持一致。

DFMGAN：首先，使用批量大小 4 对每种产品的无缺陷图像进行 3000 次迭代训练 StyleGAN2。随后，使用批量大小 4 将预训练的 StyleGAN2 微调为每个缺陷类别的缺陷图像。所有其他参数均遵循官方文档。

Defect-Gen：两个模型都经过 200,000 次迭代的训练，所有其他设置均与官方文档一致。

1.3 分类比较

为了验证生成的缺陷图像在分类任务中的作用，我们使用与分割实验中相同的数据集来训练 ResNet50 进行二元分类。每个产品都训练了 2000 个 epoch，学习率为 0.0002，批量大小为 12。MVTec 的平均分类精度如表 1 所示。1，我们的 DefectDiffu 实现了最佳分类性能。

表1：钴 分类实验的比较。AA代表平均值 准确性。

Method	Baseline	DefectDiffu(Ours)	DFMGAN	Defect-Gen	StyleGAN
AA	81.13%	91.74%	88.15%	89.75%	87.26%

表 2: MVTecAD 数据集缺陷名称: defect 指原始缺陷名称, uni_defect 指训练中使用的修改后的缺陷名称, product 指产品名称

product	defect	uni_defect	product	defect	uni_defect
metal_nut	scratch	scratch	hazelnut	print	print
	flip	flip		hole	hole
	color	color		cut	cut
	bent	bent		crack	crack
carpet	hole	hole	wood	scratch	scratch
	metal_contamination	metal_contamination		combined	combined
	cut	cut		hole	hole
	thread	thread		liquid	liquid
screw	color	color	capsule	color	color
	scratch_neck	scratch		scratch	scratch
	thread_top	thread		faulty_imprint	faulty_imprint
	scratch_head	scratch		squeeze	squeeze
leather	manipulated_front	manipulated_front	grid	crack	crack
	thread_side	thread		poke	hole
	glue	liquid		broken	broken
	cut	cut		glue	liquid
pill	color	color	zipper	metal_contamination	metal_contamination
	scratch	scratch		thread	thread
	faulty_imprint	faulty_imprint		bent	bent
	combined	combined		rough	rough
cable	contamination	contamination	tile	fabric_border	cut
	pill_type	pill_type		combined	combined
	crack	crack		fabric_interior	cut
	color	color		squeezed_teeth	squeeze
transistor	missing_cable	missing	bottle	broken_teeth	broken
	missing_wire	missing		split_teeth	split
	cable_swap	cable_swap		rough	rough
	bent_wire	bent		gray_stroke	color
toothbrush	poke_insulation	hole	toothbrush	glue_strip	glue_strip
	combined	combined		oil	liquid
	cut_inner_insulation	cut		crack	crack
	cut_outer_insulation	cut		contamination	contamination
transistor	cut_lead	cut	toothbrush	broken_small	broken
	damaged_case	damaged_case		broken_large	broken
	misplaced	misplaced		defective	bent
	bent_lead	bent			

1.4 VISA和KSDD数据集上的实验

我们在相同设置下的 KSDD 和 VISA 数据集上测试了我们的方法。实验结果如表A和表B所示。

表 A：平均定量结果的比较。

Dataset	Index	Baseline	DefectDiffu	DefectGen	DFMGAN
VisA	FID	\	39.24	185.91	180.15
	LPIPS (%)	\	10.84	10.57	7.15
	IoU (%)	44.44	53.34	47.88	46.78
	F1 (%)	57.75	66.65	61.72	60.49
	AP (%)	63.96	71.26	68.15	67.19
	AUC (%)	98.16	98.81	98.25	98.15
KSDD2	FID	\	47.92	320.60	365.56
	LPIPS (%)	\	2.89	4.32	1.75
	IoU (%)	63.96	66.08	65.17	63.32
	F1 (%)	78.02	79.58	78.91	77.54
	AP (%)	85.33	87.52	87.32	85.50
	AUC (%)	98.66	99.53	99.45	99.36

表 B：每种产品的 mIoU 比较。

VisA	candle	capsules	cashew	chewinggum	fryum	macaroni1	macaroni2	pcb1	pcb2	pcb3	pcb4	pipe_fryum
Baseline	8.06	45.58	81.32	54.01	69.12	25.49	15.52	66.46	27.26	26.43	39.03	75.04
DefectDiffu	29.18	62.12	86.89	61.81	79.83	28.08	24.19	70.89	32.51	27.22	49.84	87.57
DefectGen	24.90	60.64	82.08	59.85	62.85	24.04	23.23	65.13	32.33	18.62	42.10	78.83
DFMGAN	19.95	49.54	79.84	57.34	78.88	27.56	22.04	71.11	23.95	19.28	49.64	62.21

1.5 额外的零样本生成结果

我们验证了零样本生成在木材、瓷砖和皮革上的有效性，结果如图 1 所示。

1.6 所有类型缺陷的可控生成结果优势

我们对 MVTecAD 数据集中的所有缺陷产品进行可控缺陷图像生成。各种缺陷类型的生成结果如图 2-图 2 所示。16，展示了我们的模型对缺陷强度的强大可控性。




图 1: 瓷砖、皮革和木材的零次缺陷生成结果。




图 2：类别瓶子下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据，而 w_d 代表从左到右增加的缺陷强度。




图 3: 电缆类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 4: 类别胶囊下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 5: 地毯类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 6: 类别网格下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 7: 榛子类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据，而 w_d 代表从左到右增加的缺陷强度。




图 8: 皮革类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 9: metal_nut 类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据，而 w_d 代表从左到右增加的缺陷强度。




图 10: 药丸类别下不同类型缺陷的不同缺陷强度的结果。MVTEC AD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 11: 螺钉类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 12: 类别图块下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 13: 牙刷类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 14: 晶体管类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 15: 木材类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。




图 16: 拉链类别下不同类型缺陷的不同缺陷强度的结果。MVTecAD 代表真实数据, 而 w_d 代表从左到右增加的缺陷强度。